


Neural Grapheme-to-Phoneme Conversion with Pre-trained Grapheme Models



정보융합공학과 AI전공 정주경















목 차



- 1. Introduction
- 2. Proposed Method
- 3. Experiments
- 4. Results
- 5. Conclusion

Introduction

I G2P

- 초기: joint n-gram model, joint sequence model, WFST
- 최근: neural networks(LSTM, Transformer)

■ GBERT(Grapheme BERT)

- Transformer 기반 G2P 모델 개선
- Multi-layer Transformer encoder, grapheme만 있는 데이터로 self-supervised 사전 학습
- Masked grapheme 예측

Ⅰ GBERT Transformer 개선

- 1. GBERT fine-tuning
- 2. GBERT를 Transformer model에 attention하여 fused(융합) => BERT-fused[1]



Proposed Method

I Grapheme BERT(GBERT)

- Multi-layer bidirectional Transformer encoder
- GBERT: 한 단어의 grapheme sequence vs BERT: 한,두 문장 wordpiece sequence
- Single-word G2P task 초점(단일 단어 grapheme sequence만 고려)
- Masked grapheme 예측 작업을 통해 사전 학습
- => input grapheme 일부 랜덤 masking하고 masked grapheme 예측
- Mask token(80%), random grapheme(10%), original grapheme(10%)




Fig. 1. The masked grapheme prediction task for pre-training GBERT. Here is an example of the English word *drollery*. The "_" denotes the mask token.



Proposed Method

Fine-tuning GBERT for G2P conversion


- Vanila Transformer encoder를 GBERT로 대체하고 end-to-end로 학습
- 사전 학습된 인코더와 randomly initialized 디코더에 서로 다른 learning rate 사용하면 더 나은 수렴[1]

I Fusing GBERT into Transformer-based G2P model

- 사전 학습된 언어 모델을 통합하는 또 다른 방법은 feature extractor
- BERT-fused: vanila Transformer 인코더, 디코더 레이어와 BERT output feature 상호 작용
- ⇒ medium-resource 기계 번역에서 fine-tuning보다 더 잘 작동

부산대학교

BERT-fused





Proposed Method

I Fusing GBERT into Transformer-based G2P model




Fig. 2. The architecture of GBERT-fused model, which fuses GBERT into the Transformer-based G2P model and is adapted from [16].

Experiments

G2P Dataset

- SIGMORPHONE 2021 G2P task dataset
- Medium-resource 10개 언어 중 가장 어려운 4개 언어 선택
- 학습(8,000), 검증(1,000), 테스트(1,000)
- 한글 자모 사용(가감 -> ㄱ ㅏ ㄱ ㅏ ㅁ)
- Low-resource: 학습 셋에서 1000개 샘플링

Table 1. The four languages used in our experiments.

	0 0		1
Language	Language Family	Script Type	Word Example
Dutch	Germanic	Latin	afnemer
Serbo-Croatian	South Slavic	Latin	buđenje
Bulgarian	East Slavic	Cyrillic	абоната
Korean	Koreanic	Hangul	가치관

GBERT Dataset

- GBERT 사전 학습 위해 WikiPron에서 데이터 수집
- 검증 및 테스트셋 단어 제외
- 각 언어 90% 학습, 10% 검증

GBERT 데이터

네덜란드어	세르보크로아티아	불가리아어	한국어
27,000	35,000	43,100	14,100

Experiments

I Implementation

- Masked grapheme ratio: 20%
- 한 단어의 평균 grapheme 수가 평균 단어 수 보다 작음
- ⇒ 낮은 비율은 모델이 grapheme간의 문맥적 관계 발견X

Table 3. The influence of the masked grapheme ratio for pre-training GBERT on the performance of the GBERT attention model for the medium-resource Dutch G2P task.

Mask Ratio (%)	Mask Accuracy (%)	WER (%)	PER (%)
15	53.01	16.34 ± 0.43	3.51 ± 0.08
20	53.48	15.86 ± 0.21	3.38 ± 0.07
30	51.32	15.88 ± 0.30	3.40 ± 0.08

Masked grapheme 예측 정확도

네덜란드어	세르보크로아티아	불가리아어	한국어
53.48%	58.43%	80.66%	40.63%



Experiments

Model

Imitation Learning	SIGMORPHON 2021 모방 학습 단일 모델
Transformer	Transformer 기반 아키텍처
GBERT w/o fine-tuning	GBERT 파라미터 고정(frozen)
GBERT fine-tuning	Pre-trained GBERT encoder + Transformer decoder
GBERT attention	BERT-fused기반

부산대학교 PUSAN NATIONAL UNIVERSITY

Results

Table 2. The WER and PER results (%) of different models on our medium-resource and low-resource G2P tasks.

Model	Dut	ch	Serbo-C	Croatian	Bulga	ırian	Kor	ean
Wiodei	WER	PER	WER	PER	WER	PER	WER	PER
medium-resource								
IL [21]	17.7 ± 1.3	-	38.9 ±1.2	-	19.7 ± 1.7	-	18.9 ± 0.8	-
Transformer	16.86 ± 0.14	3.49 ± 0.05	39.50 ± 0.71	7.94 ± 0.14	20.72 ± 2.70	3.84 ± 0.74	19.26 ± 0.48	3.39 ± 0.10
GBERT w/o fine-tuning	19.98 ± 0.66	4.61 ± 0.48	43.92 ± 0.97	9.53 ± 0.75	23.24 ± 2.54	4.17 ± 0.40	23.06 ± 0.30	4.92 ± 0.15
GBERT fine-tuning	16.18 ± 0.23	3.59 ± 0.39	39.08 ± 1.05	7.83 ± 0.21	18.88 ± 2.31	3.42 ± 0.33	19.80 ± 0.62	3.52 ± 0.12
GBERT attention	15.86 ± 0.21	3.38 ± 0.07	37.64 ± 0.71	7.67 ± 0.20	18.60 ± 1.92	3.42 ± 0.34	17.94 ± 0.71	3.16 ± 0.13
low-resource								
Transformer	34.30 ± 0.66	9.39 ± 0.42	68.86 ± 1.08	15.41 ± 0.16	33.06 ± 1.90	6.07 ± 0.35	29.72 ± 0.77	6.79 ± 0.35
GBERT w/o fine-tuning	34.56 ± 0.72	9.13 ± 0.60	69.70 ± 0.69	15.88 ± 0.65	41.87 ± 0.89	9.15 ± 0.88	42.76 ± 1.04	12.66 ± 0.29
GBERT fine-tuning	28.96 ± 0.69	6.94 ± 0.61	63.12 ± 0.76	13.29 ± 0.57	30.86 ± 1.66	5.30 ± 0.36	32.78 ± 1.21	8.43 ± 0.11
GBERT attention	35.28 ± 0.66	9.41 ± 0.33	68.14 ± 0.68	15.06 ± 0.29	31.98 ± 1.32	5.76 ± 0.35	29.78 ± 0.60	6.81 ± 0.30

한국어 성능

- 마스크 예측 정확도가 낮음 => 한국어의 grapheme간 문맥 관계가 약함

부산대학교 PUSAN NATIONAL UNIVERSITY

Results


I Transfer Learning

- 저자원 성능 향상 위해 고자원 언어 같이 사용하는 GBERT기반 transfer learning 실험
- 저자원 언어: 네덜란드어, 고자원 언어:영어 => 게르만어족, 라틴어 문자 유형
- 사전 학습 데이터: WikiPron의 49,100개 영어 + 1,000개 네덜란드어

Table 4. transfe	er learning	
Model	WER	PER
Transformer	24.54 ± 0.53	5.09 ± 0.22
GBERT w/o fine-tuning	33.30 ± 0.89	7.89 ± 0.25
GBERT fine-tuning	23.42 ± 0.82	4.84 ± 0.16
GBERT attention	23.36 ± 0.82	4.76 ± 0.25

	Dutch		
Model	WER	PER	
medium-resource			
IL [21]	17.7 ± 1.3	-	
Transformer	16.86 ± 0.14	3.49 ± 0.05	
GBERT w/o fine-tuning	19.98 ± 0.66	4.61 ± 0.48	
GBERT fine-tuning	16.18 ± 0.23	3.59 ± 0.39	
GBERT attention	15.86 ± 0.21	3.38 ± 0.07	
low-resource			
Transformer	34.30 ± 0.66	9.39 ± 0.42	
GBERT w/o fine-tuning	34.56 ± 0.72	9.13 ± 0.60	
GBERT fine-tuning	28.96 ± 0.69	6.94 ± 0.61	
GBERT attention	35.28 ± 0.66	9.41 ± 0.33	

Table 2. Dutch result



Conclusion

- Pre-trained grapheme model GBERT 제안
- Transformer기반 G2P model 향상 위해 GBERT fine-tuning, GBERT attention
- GBERT attention 중간자원에서 모두 효과적
- GBERT fine-tuning 저자원에서 대부분 언어 효과적
- transfer learning을 통해 저자원 성능 향상